你說：

一、作業目標：
本次作業延伸自 HW1，目標是讓同學能夠以實際資料集進行「多元線性回歸 (Multiple Linear Regression)」的完整分析，並遵循 CRISP-DM 流程完成從資料理解、建模到評估的全過程。\

二、作業內容：
1. 資料來源
 至 Kaggle 選擇一個具有 10 至 20 個特徵 (features) 的公開資料集。
 類型不限（可為房價預測、醫療、車輛效能等主題）。
 請明確標示資料集來源與連結。
2. 分析任務
 使用線性回歸 (Linear Regression) 模型進行預測。
 可嘗試單純線性回歸、多元線性回歸或 Auto Regression。
 必須執行 **特徵選擇 (Feature Selection)** 與 **模型評估 (Model Evaluation)**。
 結果部分需包含請提供預測圖(加上信賴區間或預測區間)
3. CRISP-DM 流程說明
  Business Understanding
  Data Understanding
  Data Preparation
  Modeling
  Evaluation
  Deployment

4. AI協助要求
 所有與 ChatGPT 的對話請以 pdfCrowd 或其他方式須**匯出為 PDF**
 請**使用 NotebookLM** 對網路上同主題的解法進行研究，並撰寫一份 100 字以上的摘要，放入報告中。
 請在報告中明確標示「GPT 輔助內容」與「NotebookLM 摘要」
5. 繳交內容
 主程式：7114056XXX_hw2.py/.ipynb
 報告檔： PDF，需包含以下內容：
  按照 CRISP-DM 說明的分析流程
  GPT 對話過程（pdfCrowd 匯出）
  NotebookLM 研究摘要
  網路上主流或更優解法之比較與說明
 以上檔案與資料夾**請壓縮為學號命名的一個zip**（例如 7114056XXX_hw2.zip）上傳。

 (optional) 若上傳至 GitHub，或是以colab撰寫，需提供連結，並在 README.md 中整理流程與成果。

三、評分標準
 文件說明（50%）
  CRISP-DM 流程完整且邏輯清楚（25%）
  包含 GPT 對話與 NotebookLM 摘要（15%）
  有明確說明資料集來源與研究脈絡（10%）
 結果呈現（50%）
  模型正確可執行，具特徵選擇與評估（25%）
  結果合理、美觀且具有說服力（15%）
  呈現出Kaggle名次(若有)/預測結果評估(預測圖、評估指標)（10%）

list kaggle multiple linear regression problems , choose features > 13, < 40

Kaggle Multiple Linear Regression Problems (14–

39 Features)

你希望找適合 **Multiple Linear Regression（多元線性回歸）** 的 Kaggle 題目，條件為：
13<Number of Features<4013<Number of Features<40
也就是 **14–39 個輸入特徵**，不包含 Target（預測目標）。
建議優先選擇連續數值預測（Regression）、可使用 `sklearn.LinearRegression` 、適合進行 Feature Selection、MSE、RMSE、R^2 與五大回歸假設檢驗的資料集。
特別注意：Kaggle 上常見的 House Prices — Advanced Regression Techniques 有 **79 個原始特徵**，不符合你的原始特徵數限制，但可以透過特徵選擇建立 14–39 特徵的練習版本。
www.kaggle.com&sz=32
Kaggle
+1

Recommended Kaggle Regression Problems

以下區分「原始特徵符合條件」與「需要 Feature Selection 才符合條件」。

#	Kaggle Problem	Features	Target	Suitability
1	Predict the Flood	20	FloodProbability	Excellent
2	Flood Prediction Dataset	20	FloodProbability	Excellent

3			
Istanbul Apartment Prices 2026			
29 or fewer*			
Price			
Good			
4			
Swiss Housing Price Prediction			
30			
House price			
Good; restricted access			
5			
Human–AI Interaction			
20			
Trust score			
Excellent; synthetic			
6			
House Prices — Advanced Regression			
79 → select 20–30			
SalePrice			
Excellent for feature selection *Istanbul 資料集描述為 30 欄，包含價格等欄位；精確輸入特徵數需檢查 CSV。上述資料集的特徵數以來源描述為準，類別編碼後可能增加。			

www.kaggle.com&sz=32
Kaggle
+5

My Top 3 for Teaching

China's Yellow River will be choked by ice jams due to global warming, study finds | South China Morning Post
1. Predict the Flood
20 numerical features, continuous target. Best for teaching OLS, MSE, R^2, residual analysis and regression assumptions.
Aerial View of Houses
2. Istanbul Apartment Prices
Suitable for categorical encoding, feature selection, and housing-price regression. Check the dataset columns before modeling.
AISCA
3. Human–AI Interaction
20 original features, 10,100 samples. Useful for studying coefficients, categorical features and multicollinearity.

Suggested Assignment: CRISP-DM + Feature Selection

For any selected dataset, students can complete:

1. **Business Understanding:** Define the continuous prediction target.
2. **Data Understanding:** Verify sample size, feature count, missing values and correlations.
3. **Data Preparation:** Train/test split, missing-value handling and categorical encoding.
4. **Modeling:** Train `LinearRegression`, Ridge and Lasso.
5. **Evaluation:** Compare MAE, MSE, RMSE, R^2 and Adjusted R^2; check the five regression assumptions.
6. **Deployment:** Predict new samples and explain the model.

For Feature Selection, compare **SelectKBest, RFE, Sequential Feature Selection, Lasso and permutation importance**, selecting 14, 20, 25 or 30 features using training data only.
My first choice is Predict the Flood, because its 20 numerical features meet your constraint directly and avoid the extra complexity of categorical encoding.

ChatGPT 說：

根據你的 HW2 作業要求，我建議優先選擇 **14–39 個輸入特徵、預測目標為連續數值，而且能直接下載 CSV 的 Kaggle 資料集**。這樣比較容易完成多元線性回歸、Feature Selection、模型評估、預測區間，以及完整的 CRISP-DM 報告。

除了資料集本身，還要考慮兩件事：

- **作業容易完成：** 最好以數值特徵為主，避免花太多時間處理類別欄位。
- **報告容易拿分：** 要能解釋為什麼選擇某些特徵、比較不同模型，並用預測圖和區間呈現結果。

一、符合條件的 Kaggle 題目

以下是值得考慮的選項。特徵數指的是原始輸入特徵，不包含預測目標；正式使用前仍應檢查下載後的 CSV 欄位。



1. Predict the Flood

最推薦

20 個數值特徵｜目標：FloodProbability

- 優點：數值資料為主，適合多元線性回歸、Forward Selection、R^2、MAE、RMSE。
- 缺點：資料是合成資料，不宜直接當成真實洪水預測的科學證據。
- 適合程度：非常適合課堂建模與特徵選擇練習。

Kaggle 資料集與競賽頁面 ↗ k Kaggle



2. Istanbul Apartment Prices 2026

欄位數需確認｜目標：Price

- 優點：房價主題直觀，容易製作實際值與預測值比較圖。
- 缺點：可能包含類別欄位、文字與缺失值，需要額外清理。
- 注意：下載後確認不含目標欄位的特徵數是否符合 14–39 個。

Kaggle 資料集



3. House Prices — Advanced Regression Techniques

79 個原始預測欄位｜目標：SalePrice

- 優點：房價研究資源豐富，可以比較不同特徵選擇方法及更進階的模型。
- 缺點：原始特徵數超出你的限制，必須先選出 14–39 個特徵。
- 適合程度：適合想做較完整的房價分析，但資料準備工作較多。

Kaggle 競賽頁面 nycdatascience.c



4. Concrete Strength - Regression

8 個原始輸入特徵｜目標：抗壓強度

- 優點：資料乾淨，適合回歸分析。
- 缺點：只有 8 個原始輸入特徵，**不符合你設定的 14–39 個特徵條件**。
- 除非老師允許使用特徵工程增加欄位，否則不建議選它。

Kaggle 競賽頁面 k Kaggle

二、我建議你選哪一個？

我會選第一個：**Predict the Flood**。

原因是它有 20 個數值特徵，符合你的條件，而且可直接將 Feature Selection 和模型評估放在同一份 Notebook 中完成。 k Kaggle

需要注意，這個競賽的資料是合成的，並非直接採集的真實洪水觀測資料；報告的研究限制應明確說明。 k Kaggle

三、你的 HW2 可以怎麼設計？

作業項目	建議實作
Business Understanding	預測洪水發生機率，分析風險因子與預測能力
Data Understanding	資料筆數、20 個特徵、統計摘要、相關係數矩陣
Data Preparation	檢查缺失值、資料型態、訓練集與測試集切分
Modeling	Multiple Linear Regression、Forward Selection、Ridge、Lasso
Evaluation	R^2、MAE、RMSE、殘差分析、實際值與預測值圖
Prediction Interval	使用統計回歸模型計算 95% 預測區間
Deployment	輸出預測結果、建立可重現的 Notebook 或 Python 程式

預測圖建議同時呈現實際值、預測值及 95% 預測區間。要特別區分：**預測區間（Prediction Interval）**是針對單筆未來觀測值的範圍，不等同於迴歸平均值的信賴區間（Confidence Interval）。

四、報告還有兩個重要要求

1. **NotebookLM 摘要：** 搜尋同主題的回歸研究或 Kaggle 解法，放入 NotebookLM 比較後，撰寫至少 100 字的摘要，並保留參考來源。
2. **GPT 輔助內容：** 匯出你與 ChatGPT 的相關對話為 PDF，與分析報告一起繳交。報告中要清楚區分 GPT 輔助內容與 NotebookLM 摘要。

另外，Kaggle 排名只有在實際參賽並提交預測結果後，才能填寫真實名次；如果沒有提交，就應如實標示未參賽，而不是自行填寫排名。

下一步建議： 先確認你要使用的 Kaggle 資料集，再開始撰寫完整的 `.ipynb` 、報告與 README，避免做到一半才發現特徵數或資料來源不符合要求。

你說：

好 第一個

ChatGPT 說：

好！我們就選第一個 **Kaggle：Predict the Flood** 作為你的 HW2 專題。

我會以老師的評分標準為主，讓你最後能整理出完整的 Python 程式、分析報告 PDF、GPT 對話 PDF、NotebookLM 摘要，以及學號命名的 ZIP 壓縮檔。

一、先確定專題設定



Flood Probability Prediction

洪水機率預測與多元線性回歸分析

資料來源：Kaggle Predict the Flood

輸入特徵	預測目標
20 個	FloodProbability

注意：開始分析前仍須核對下載資料的實際欄位與版本。這類競賽資料為合成資料，報告中會說明研究限制。

五、現在請先完成資料下載

1. 打開 Kaggle Predict the Flood 資料頁 。
2. 登入 Kaggle，確認你有權限查看並下載資料。這個競賽頁目前顯示需要邀請權限，因此如果無法存取，不要卡在這一步。 Kaggle
3. 下載訓練資料 CSV。通常我們需要有 `FloodProbability` 目標欄位的訓練資料，才能進行模型訓練與評估。
4. 把下載的檔案放進你準備好的 HW2 專案資料夾。

如果你想直接使用可公開取得的替代資料，也可以查看 Kaggle Flood Prediction Dataset 。

接下來我可以帶你用 VS Code 一步一步完成整份作業，包括程式碼、Forward Selection、95% 預測區間、CRISP-DM 報告及 ZIP 打包。

先問你一個問題：**你的學號是什麼？** 我可以直接依照老師要求幫你設定主程式與壓縮檔的命名格式。

你說：

如何下載 ,7115056187

ChatGPT 說：

你的學號我會使用 `7115056187`，所以最後的檔案名稱會是 `7115056187_hw2.ipynb`、`7115056187_hw2.pdf` 和 `7115056187_hw2.zip`。

不過，我查到一個重要問題：你選的 Kaggle 競賽目前標示 **Invitation required（需要邀請權限）**。 k Kaggle 我們先試著下載；如果無法存取，就改用可公開下載的替代資料，不要浪費時間。

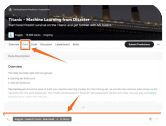
第一步：下載 Kaggle 資料



1. 開啟資料下載頁面

點擊以下連結：

前往 Predict the Flood →



2. 登入 Kaggle

如果沒有帳號，先註冊；如果看到同意競賽規則的按鈕，先閱讀並接受規則。若頁面要求邀請權限，請看下方的替代方案。



3. 下載 CSV

找到頁面中的 `Download All`，下載後通常會得到 ZIP 壓縮檔。解壓縮後，確認是否有訓練資料 CSV。

第二步：如果出現 Invitation required

建議改用這個公開的洪水預測資料集：

Kaggle — Regression with a Flood Prediction Dataset

這個資料集同樣以 `FloodProbability` 為預測目標，適合練習多元線性回歸。 k Kaggle

第三步：下載完成後

請把解壓縮後的檔案放到 VS Code 專案資料夾。我們預計整理成以下結構：

```
7115056187_hw2/
├── 7115056187_hw2.ipynb
├── data/
│   └── train.csv
├── report/
│   ├── 7115056187_hw2.pdf
│   └── GPT_conversation.pdf
├── README.md
└── requirements.txt
```

最後再將整個資料夾壓縮為 `7115056187_hw2.zip`。

你現在先點開第一個 Kaggle 連結，告訴我你看到哪一種畫面：

A. 要我登入或註冊

B. 顯示 Invitation required

C. 已經看到 CSV 檔案或 Download All

D. 其他錯誤或不知道怎麼操作

下一步

你說：

改用公開的

ChatGPT 說：

好，我們改用公開頁面上的洪水預測資料。你可以先從下面這個 Kaggle 連結下載，它有 `train.csv` 、 `test.csv` 和 `sample_submission.csv` ，目標欄位是 `FloodProbability` ，符合我們要做的回歸分析方向。 Kaggle

第一步：開啟公開資料頁

kaggle
Regression with a Flood Prediction Dataset
Kaggle 公開競賽資料頁

點此開啟資料下載頁面

開啟 Kaggle

第二步：照著畫面下載

1. 登入 Kaggle。
2. 如果看到 **Join Competition**，點擊加入並依頁面要求接受規則。
3. 進入 **Data** 頁籤。
4. 找到 **Download All**，下載 ZIP 檔。
5. 解壓縮後，確認有 `train.csv` 。

這份資料約 104 MB，並採用 CC BY 4.0 授權。 Kaggle

第三步：放進 VS Code

建立專案資料夾 `7115056187_hw2` ，再把 `train.csv` 放進 `data` 子資料夾：

```
7115056187_hw2/
└── data/
    └── train.csv
```

如果這個連結仍要求特殊權限，請不要勉強使用。 你可以改用較成熟的公開競賽資料：Kaggle Playground Series S4E5 ，這是 2024 年的洪水機率回歸競賽，有相同的 `FloodProbability` 預測目標與 20 個輸入特徵。 Kaggle

你先試試看上面的下載連結。如果已經下載成功，回覆我「下載好了」；如果畫面出現錯誤，就把錯誤訊息或截圖傳給我，我會接著帶你完成下一步。

你說：

下載好了

ChatGPT 說：

太好了！接下來我們開始用 **VS Code 完成 HW2：洪水機率預測與多元線性回歸**。

你的學號是 `7115056187` ，所以程式、報告和最後的 ZIP 都會使用這個學號命名。我們先確認資料可以正常讀取，再依序完成特徵選擇、模型評估、95% 預測區間與 CRISP-DM 報告。

第一步：建立 VS Code 專案資料夾

請先把下載的 ZIP 解壓縮，找到裡面的 `train.csv` 。

建立以下資料夾結構：

- 7115056187_hw2/
  - data/
    - train.csv

在 VS Code 裡選擇 **File → Open Folder...**，開啟 `7115056187_hw2`。

如果下載的 ZIP 裡還有 `test.csv`、`sample_submission.csv`，也可以一併保留；目前先使用 `train.csv` 建模。

第二步：在 VS Code 安裝 Python 套件

在 VS Code 上方選單點選 **Terminal → New Terminal**，依序輸入以下指令。

1. 建立虛擬環境

如果你使用 Mac，輸入：

```
python3 -m venv .venv
source .venv/bin/activate
```

成功後，終端機前面通常會出現 `(.venv)`。

2. 安裝需要的套件

```
python -m pip install --upgrade pip
python -m pip install pandas numpy matplotlib seaborn scikit-learn statsmodels scipy jupyter
```

這些套件會用於資料分析、線性回歸、特徵選擇、繪圖和統計分析。

第三步：確認資料是否正確

在 VS Code 左側檔案總管，新增一個 Python 檔案：

`7115056187_hw2.py`

把下面的程式碼完整貼進去。

```
from pathlib import Path

import pandas as pd

# 讀取訓練資料
DATA_PATH = Path("data/train.csv")

if not DATA_PATH.exists():
    raise FileNotFoundError(
        f"找不到 {DATA_PATH}，請確認 train.csv 已放進 data 資料夾。"
    )

df = pd.read_csv(DATA_PATH)

print("=" * 60)
print("HW2：Flood Probability Prediction")
print("=" * 60)
```

```
print("\n【資料集大小】")
print(f"資料筆數：{df.shape[0]:,}")
print(f"總欄位數：{df.shape[1]}")

print("\n【欄位名稱】")
print(df.columns.tolist())

print("\n【前 5 筆資料】")
print(df.head())

print("\n【資料型態】")
print(df.dtypes)

print("\n【缺失值統計】")
print(df.isnull().sum())

print("\n【數值欄位統計摘要】")
print(df.describe().T)

target = "FloodProbability"

if target in df.columns:
    print("\n【預測目標統計】")
    print(df[target].describe())

    feature_cols = [col for col in df.columns if col != target]
    print(f"\n輸入特徵數：{len(feature_cols)}")

    if 13 < len(feature_cols) < 40:
        print("特徵數符合 14–39 個的作業條件。")
    else:
        print("注意：特徵數不符合 14–39 個的條件，請檢查資料集。")
else:
    print(f"\n找不到 {target} 欄位，請確認使用的是訓練資料。")
```

第四步：執行程式

在 VS Code 終端機輸入：

```
python 7115056187_hw2.py
```

如果一切正常，你會看到資料筆數、欄位名稱、缺失值，以及輸入特徵數。

第五步：把結果傳給我

請把執行結果中的這三項貼給我：

- 資料集大小
- 欄位名稱
- 輸入特徵數

我會依照你**實際下載的資料**，接著幫你完成多元線性回歸、Forward Selection 特徵選擇、R^2 / MAE / RMSE 評估，以及附有 95% 預測區間的圖表，避免因為資料版本不同而產生錯誤。

你說：

```
[Running] python -u "/Users/pengjie/Documents/7115056187_hw2/7115056187_hw2.py"
============================================================
HW2：Flood Probability Prediction
============================================================
```

【資料集大小】
資料筆數：1,117,957
總欄位數：22

【欄位名稱】
['id', 'MonsoonIntensity', 'TopographyDrainage', 'RiverManagement', 'Deforestation', 'Urbanization', 'ClimateChange', 'DamsQuality', 'Siltation', 'AgriculturalPractices', 'Encroachments', 'IneffectiveDisasterPreparedness', 'DrainageSystems', 'CoastalVulnerability', 'Landslides', 'Watersheds', 'DeterioratingInfrastructure', 'PopulationScore', 'WetlandLoss', 'InadequatePlanning', 'PoliticalFactors', 'FloodProbability']

【前 5 筆資料】

	id	MonsoonIntensity	...	PoliticalFactors	FloodProbability
0	0	5	...	3	0.445
1	1	6	...	3	0.450
2	2	6	...	3	0.530
3	3	3	...	5	0.535
4	4	5	...	5	0.415

[5 rows x 22 columns]

【資料型態】
id int64
MonsoonIntensity int64
TopographyDrainage int64
RiverManagement int64
Deforestation int64
Urbanization int64
ClimateChange int64
DamsQuality int64
Siltation int64
AgriculturalPractices int64
Encroachments int64
IneffectiveDisasterPreparedness int64
DrainageSystems int64
CoastalVulnerability int64
Landslides int64
Watersheds int64
DeterioratingInfrastructure int64
PopulationScore int64
WetlandLoss int64
InadequatePlanning int64
PoliticalFactors int64
FloodProbability float64
dtype: object

【缺失值統計】
id 0
MonsoonIntensity 0
TopographyDrainage 0
RiverManagement 0
Deforestation 0
Urbanization 0
ClimateChange 0
DamsQuality 0
Siltation 0
AgriculturalPractices 0
Encroachments 0
IneffectiveDisasterPreparedness 0
DrainageSystems 0
CoastalVulnerability 0
Landslides 0
Watersheds 0

```
DeterioratingInfrastructure       0
PopulationScore                   0
WetlandLoss                       0
InadequatePlanning                0
PoliticalFactors                  0
FloodProbability                  0
dtype: int64

【數值欄位統計摘要】
                                 count  ...         max
id                           1117957.0  ...  1117956.000
MonsoonIntensity             1117957.0  ...       16.000
TopographyDrainage           1117957.0  ...       18.000
RiverManagement              1117957.0  ...       16.000
Deforestation                1117957.0  ...       17.000
Urbanization                 1117957.0  ...       17.000
ClimateChange                1117957.0  ...       17.000
DamsQuality                  1117957.0  ...       16.000
Siltation                    1117957.0  ...       16.000
AgriculturalPractices        1117957.0  ...       16.000
Encroachments                1117957.0  ...       18.000
IneffectiveDisasterPreparedness  1117957.0  ...       16.000
DrainageSystems              1117957.0  ...       17.000
CoastalVulnerability         1117957.0  ...       17.000
Landslides                   1117957.0  ...       16.000
Watersheds                   1117957.0  ...       16.000
DeterioratingInfrastructure  1117957.0  ...       17.000
PopulationScore              1117957.0  ...       18.000
WetlandLoss                  1117957.0  ...       19.000
InadequatePlanning           1117957.0  ...       16.000
PoliticalFactors             1117957.0  ...       16.000
FloodProbability             1117957.0  ...        0.725

[22 rows x 8 columns]

【預測目標統計】
count    1.117957e+06
mean     5.044803e-01
std      5.102610e-02
min      2.850000e-01
25%      4.700000e-01
50%      5.050000e-01
75%      5.400000e-01
max      7.250000e-01
Name: FloodProbability, dtype: float64

輸入特徵數：21
特徵數符合 14–39 個的作業條件。

[Done] exited with code=0 in 3.308 seconds
```

ChatGPT 說：

很好！你的程式已經成功執行，而且這份資料非常適合繼續完成 HW2。從輸出結果來看，資料讀取正常、沒有缺失值，輸入特徵數也符合老師的要求。

不過，我們要先做一個重要的資料處理：`id` **是資料識別編號，不應當作預測洪水機率的特徵**。因此，實際建模時會排除 `id`，使用其餘 20 個特徵預測 `FloodProbability`。

一、目前的資料檢查結果

資料筆數	有效預測特徵
1,117,957	20 個

1,117,957 20 個

目標欄位：FloodProbability。資料沒有缺失值，且包含超過 111 萬筆觀測值，足以進行訓練集與測試集切分。

你的資料中， `FloodProbability` 的平均值約為 0.5045，標準差約為 0.0510，最小值為 0.285、最大值為 0.725。

要注意：這些數值是資料集中的預測目標統計，不代表真實世界的洪水發生率。

二、下一步要完成什麼？

接下來我們會依序完成：

缺失值 目標平均值

0 0.5045

1. 資料探索分析（EDA）與相關係數圖。
2. 訓練集與測試集切分。
3. 多元線性回歸模型。
4. Forward Selection 特徵選擇。
5. R^2、MAE、RMSE 評估。
6. 實際值與預測值圖，以及 95% 預測區間。
7. 再整理成符合 CRISP-DM 的報告。

三、把主程式升級成完整分析版本

請將 `7115056187_hw2.py` 原本的內容全部替換成以下程式。這個版本會自動完成資料分析、特徵選擇、模型比較、評估圖與 95% 預測區間。

```
from pathlib import Path
import warnings

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression, Ridge, Lasso
from sklearn.metrics import (
    r2_score,
    mean_absolute_error,
    mean_squared_error
)
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import make_pipeline
import statsmodels.api as sm

warnings.filterwarnings("ignore")

# ============================================================
# 1. 基本設定
# ============================================================
RANDOM_STATE = 42
TARGET = "FloodProbability"
DATA_PATH = Path("data/train.csv")
OUTPUT_DIR = Path("results")
OUTPUT_DIR.mkdir(exist_ok=True)

sns.set_theme(style="whitegrid")
```

```
plt.rcParams["figure.figsize"] = (10, 6)

# ============================================================
# 2. Data Understanding：讀取及檢查資料
# ============================================================
df = pd.read_csv(DATA_PATH)

print("=" * 65)
print("HW2：Flood Probability Prediction")
print("=" * 65)

print(f"資料筆數：{len(df):,}")
print(f"欄位數：{df.shape[1]}")
print(f"缺失值總數：{df.isnull().sum().sum()}")

# id 為識別碼，不作為預測特徵
feature_cols = [
    col for col in df.columns
    if col not in [TARGET, "id"]
]

X = df[feature_cols]
y = df[TARGET]

print(f"實際輸入特徵數：{len(feature_cols)}")
print("特徵名稱：", feature_cols)
print("\n目標變數描述：")
print(y.describe())

# ============================================================
# 3. Data Preparation：切分資料
# ============================================================
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=RANDOM_STATE
)

print(f"\n訓練集：{len(X_train):,} 筆")
print(f"測試集：{len(X_test):,} 筆")

# ============================================================
# 4. EDA：目標分布與相關係數
# ============================================================
plt.figure()
sns.histplot(y, bins=40, kde=True)
plt.title("Distribution of FloodProbability")
plt.xlabel("FloodProbability")
plt.tight_layout()
plt.savefig(OUTPUT_DIR / "01_target_distribution.png", dpi=200)
plt.close()

corr = df[feature_cols + [TARGET]].corr(numeric_only=True)

plt.figure(figsize=(15, 12))
sns.heatmap(corr, cmap="coolwarm", center=0)
plt.title("Feature Correlation Heatmap")
plt.tight_layout()
plt.savefig(OUTPUT_DIR / "02_correlation_heatmap.png", dpi=200)
plt.close()
```

```
# ============================================================
# 5. Feature Selection：Forward Selection
#    使用訓練集子樣本進行特徵選擇，避免計算成本過高
# ============================================================
selection_size = min(50000, len(X_train))

X_fs, _, y_fs, _ = train_test_split(
    X_train,
    y_train,
    train_size=selection_size,
    random_state=RANDOM_STATE
)

remaining = list(feature_cols)
selected = []
selection_history = []

# 每次加入一個能讓驗證集 R² 提升最多的特徵
X_fs_train, X_fs_val, y_fs_train, y_fs_val = train_test_split(
    X_fs, y_fs,
    test_size=0.2,
    random_state=RANDOM_STATE
)

best_score = -np.inf

# 最多選 10 個特徵；可依作業需要調整
N_FEATURES = min(10, len(remaining))

for step in range(N_FEATURES):
    candidates = []

    for feature in remaining:
        current_features = selected + [feature]

        model = LinearRegression()
        model.fit(X_fs_train[current_features], y_fs_train)

        pred = model.predict(X_fs_val[current_features])
        score = r2_score(y_fs_val, pred)

        candidates.append((score, feature))

    candidates.sort(reverse=True)
    score, best_feature = candidates[0]

    selected.append(best_feature)
    remaining.remove(best_feature)
    best_score = score

    selection_history.append({
        "Step": step + 1,
        "Feature": best_feature,
        "Validation_R2": score
    })

    print(
        f"Forward Selection 第 {step + 1} 步："
        f"{best_feature}, Validation R² = {score:.6f}"
    )
```